

Maturaarbeit

Compiler Construction

Fabio Stalder

Betreut durch
Thomas Jampen

26. September 2024



Gymnasium Kirchenfeld
Abteilung MN

Inhaltsverzeichnis

1	Einleitung	4
2	Vergleich der Compiler	5
3	Funktionsweise traditioneller Compiler	6
3.1	Lexikalische Analyse	7
3.2	Syntaktische Analyse	7
3.3	Semantische Analyse	8
3.4	Codegenerierung	9
3.5	Optimierung	9
4	Der QHScompiler	11
4.1	Die Fetch-Phase	11
4.2	Die Validate-Phase	12
4.3	Die Execute-Phase	13
4.3.1	Identifizier	13
4.3.2	Instructions	14
4.3.3	LiteralCode	15
4.4	Definition der Macros	15
4.4.1	Die QHS Notation	15
4.4.2	Beispiele zu Identifizier-Definitionen	16
4.4.3	Parameter und Rückgabewert für Identifizier	18
4.4.4	Variablen	18
4.4.5	Funktionsdefinitionen	20
5	Auswertung des Compiler Vergleichs	23
5.1	Geschwindigkeit der Kompilierung	23
5.2	Geschwindigkeit der Ausgabedatei	24
5.3	Umgang mit fehlerhaftem Code	25
5.4	Offenheit für Erweiterung	27
5.5	Fazit	27
6	Schluss	29

Während ich mich mit der Theorie hinter modernen Compilern befasste, stellte ich mir häufig die Frage: Wieso sind Compiler so, wie sie sind? Ich nahm mir daraufhin vor selbst einen alternativen Aufbau für Compiler zu entwickeln, mit dem Ziel zu verstehen, wieso sich das traditionelle Compiler Modell so gut bewährt. In dieser Maturaarbeit werde ich zuerst den traditionellen Aufbau von Compilern kurz beschreiben und mein eigenes alternatives Modell vorstellen. Die Umsetzung meiner Idee werde ich anhand eines selbstgeschriebenen alternativen Compilers erläutern. Dieser alternative Compiler wird daraufhin mit zwei traditionellen Compilern, wovon ich ebenfalls einen selbst geschrieben habe, verglichen. Zum Schluss werde ich die Resultate des Vergleichs einordnen und daraus Vor- und Nachteile des traditionellen Compiler Aufbaus ableiten.

1 Einleitung

In der Informatik beschreibt *Compiler* ein Programm, das Code aus einer Programmiersprache in eine andere Programmiersprache übersetzt. In dieser Hinsicht gleichen Compiler Übersetzern für Menschensprache. Genauso wie ein Übersetzer für die Kommunikation zwischen zwei verschiedensprachigen Menschen nötig ist, braucht man Compiler um die Kommunikation zwischen Mensch und Computer zu ermöglichen oder zumindest zu vereinfachen. Grundsätzlich ist es mit einer Assembly Sprache möglich, ohne Compiler einem Computer Befehle zu geben. Jedoch sind Assembly Sprachen, nicht besonders einfach zu verwenden. Compiler übersetzten von verständlicheren Programmiersprachen zu Assembly und ermöglichen daher ein viel einfacheres Schreiben von Programmen. Compiler unterscheiden sich jedoch grundsätzlich von Übersetzern in der Erwartungshaltung, die an sie gestellt wird. Menschensprache ist sehr komplex und nicht immer besonders eindeutig. Programmiersprachen hingegen sind so definiert, dass sie keinen Raum für Missverständnisse oder Ungenauigkeit lassen. Genauso muss auch ein Compiler exakt und fehlerfrei übersetzen. Neben fehlerfrei muss die Kompilierung auch möglichst schnell sein. Dasselbe gilt natürlich auch für die resultierende Ausgabedatei. Dieser sollte optimal generiert werden, um die schlussendliche Ausführungsdauer so kurz wie möglich zu halten. Sollte sich doch einmal ein Fehler in der Eingabedatei befinden, muss dieser verständlich gemeldet werden. Compiler sind also keine simplen Programme und daher auch bis heute ein aktives Forschungsgebiet.

Als ich mit meiner Maturaarbeit begann, war mein Ziel die Entwicklung eines einfachen Compilers zu einer C ähnlichen Programmiersprache. Unterstützt wurde ich darin freundlicherweise durch eine Vorlesung der Universität Bern. Während mir in dieser Vorlesung der theoretische Aufbau eines Compilers erklärt wurde, fragte ich mich trotzdem hin und wieder, wieso genau Compiler tatsächlich so aufgebaut sind und ob es nicht eine einfachere Möglichkeit gäbe. Als ich dann in den Sommerferien auf Probleme in der Entwicklung meines eigenen Compilers stiess, entschied ich mich einem von mir erdachten alternativen Aufbau für Compiler eine Chance zu geben.

In dieser Maturaarbeit werde ich anhand des "traditionellen" Compiler Aufbaus meine alternative Idee erklären und auf mögliche Probleme in der Umsetzung eingehen. Zum Schluss werde ich einen nach dem alternativen Aufbau entwickelten Compiler mit traditionellen Compilern vergleichen und damit Vor- und Nachteile der beiden Möglichkeiten aufzeigen. Für diese Maturaarbeit werden Grundkenntnisse von RegEx, Datenstrukturen und Assembly vorausgesetzt.

2 Vergleich der Compiler

Um die Leistung meines alternativen Aufbaus eines Compilers zu testen, werde folgende drei Compiler verglichen:

1. Der *QHScompiler* ist der von mir nach meinem Aufbau entwickelte Compiler. Seine genaue Funktionsweise wird in Abschnitt 4 ausgeführt. Er ist in C++ geschrieben und verwendet meine eigene Programmiersprache QHS als Eingabesprache.
2. *GCC* ist der gebräuchlichste Compiler für die Programmiersprache C. Veröffentlicht im Jahre 1987 wird GCC bis heute weiterentwickelt und ermöglicht inzwischen auch die Kompilierung von C++, Rust, Go, usw. Passend dazu lautet das Akronym GCC ausgeschrieben: GNU Compiler Collection. Für diesen Vergleich repräsentiert GCC den traditionellen Compiler Aufbau.
3. Der *THScompiler* ist ebenfalls ein traditioneller Compiler. Der Unterschied zu GCC liegt jedoch darin, dass der THScompiler von mir selbst entwickelt wurde. Er ist dadurch deutlich weniger optimiert und umfasst weniger Funktionen. In der Komplexität entspricht der THScompiler ungefähr dem QHScompiler. Der THScompiler dient mit ähnlichem Arbeitsaufwand, Optimierung und Niveau der Programmierung als "realistische" Konkurrenz zum QHScompiler. Geschrieben ist der THScompiler in C++ und kompiliert aus meiner eigenen Programmiersprache THS.

Für die von mir entwickelten Compiler habe ich folgende Mindestanforderungen gestellt:

Tabelle 2.1: Anforderungen an die Compiler

Ausgabe als Assembly Code	Die Ausgabesprache muss Assembly Code sein
C ähnlicher Syntax	Die Eingabesprache muss einen C ähnlichen Syntax aufweisen
Variablen und Funktionen	Lokale und globale Variablen sowie Funktionen müssen unterstützt werden
Branching und Loops	If-Statements und einfache Loops müssen umsetzbar sein

Die Kriterien des Vergleichs sind in Tabelle 2.2 aufgelistet.

Tabelle 2.2: Vergleichskriterien der Compiler

Geschwindigkeit der Kompilierung	Wie lange dauert die Kompilierung von Code?
Geschwindigkeit der Ausgabedatei	Wie lange dauert die Ausführung der Ausgabedatei?
Umgang mit fehlerhaftem Code	Wie geht der Compiler mit fehlerhaften Eingabedateien um?
Offenheit für Erweiterung	Wie einfach kann die Eingabesprache erweitert werden?

3 Funktionsweise traditioneller Compiler

Der traditionelle Aufbau eines Compilers lässt sich mit folgendem Schema veranschaulichen:

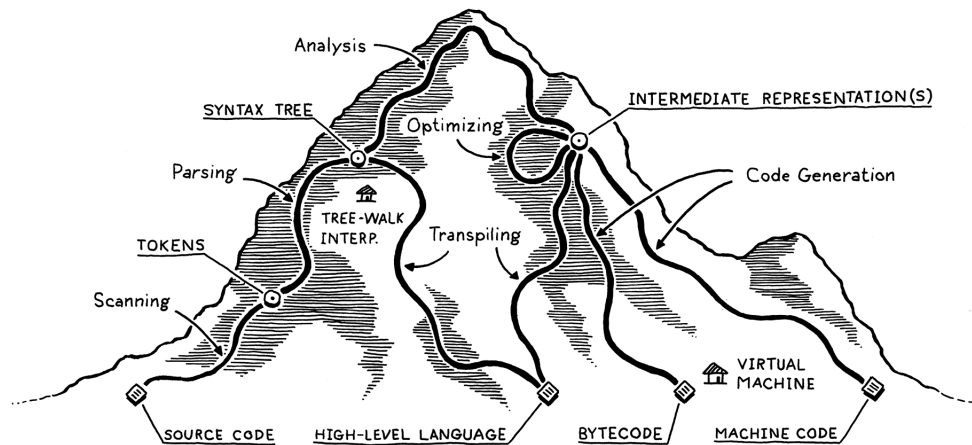


Abbildung 3.1: Schritte, die ein Compiler durchläuft

In dieser Arbeit werde ich mich auf die in der unteren Abbildung 3.2 dargestellten Schritte fokussieren.




Abbildung 3.2: Schritte, die in dieser Arbeit behandelt werden

Die von mir verwendeten Fachbegriffe entsprechen hierbei nicht immer denen aus Abbildung 3.2.

Als Basis für dieses Kapitel dient grösstenteils eine Vorlesung der Universität Bern, die ich für freundlicher-weise besuchen durfte.

3.1 Lexikalische Analyse

Meist werden Programme so geschrieben, dass wir Menschen sie lesen und verstehen können. Dafür verwendet man Buchstaben, Zahlen, Sonderzeichen (wie `+` oder `*`) und Whitespaces (wie Leerzeichen oder Absätze). Diese Zeichen sind jedoch für den Computer nicht sofort verständlich. Der erste Schritt beim Kompilieren ist daher die *lexikalische Analyse*. Diese Analyse wird von einem Teil des Compilers, dem *Lexer*, durchgeführt. Die Aufgabe dieses Lexers ist es, die Eingabedatei zu analysieren und die gefundenen Zeichen in sogenannte *Tokens* zu verwandeln. Diese Tokens sind Datenstrukturen, die der Compiler versteht und mit denen er weiterarbeiten kann.

Ein Beispiel der lexikalischen Analyse auf der Programmiersprache C:

Auflistung 3.1: C code vor lexikalischer Analyse

```
int foo()
{
    if (bar == 0)
    {
        return 0;
    }

    return 1;
}
```

Auflistung 3.2: Tokens nach lexikalischer Analyse

```
Keyword      (keyword="int")
Identifier    (id="foo")
LParenthesis
RParenthesis
Keyword      (keyword="if")
LParenthesis
Identifier    (id="bar")
Operator      (operator=ComparisonEqual)
LiteralInt    (value=0)
[...]
```

Der Lexer legt fest, welche Zeichen die Eingabe-Programmiersprache enthalten darf und welche Bedeutung ihnen zugesprochen wird. So ist zum Beispiel im Lexer festgelegt, dass ein `+` Zeichen als Addition interpretiert wird. Genauso wie im Listing 3.2 'if' als Keyword-Token gesehen wird, lässt sich im Lexer auch bestimmen, dass ein Wort wie 'else' als Keyword angesehen werden soll.

3.2 Syntaktische Analyse

Der Compiler hat nun die Zeichen der Eingabedatei in ein für ihn verständliches Format übersetzt. Jedoch fehlt dem Compiler noch das Verständnis für die Syntax der Eingabe-Programmiersprache. Die meisten High-Level Programmiersprachen weisen Syntaxregeln auf. Diese beinhalten, wie Funktionen und Variablen definiert werden oder mit welchen Punktvorstrich-Regeln Expressions evaluiert werden. In diesem Schritt führt der sogenannte *Parser* die *syntaktische Analyse* durch. Dabei werden die bei der lexikalischen Analyse gefundenen Tokens ineinander verschachtelt und in einen sogenannten *Abstract Syntax Tree (AST)* überführt.

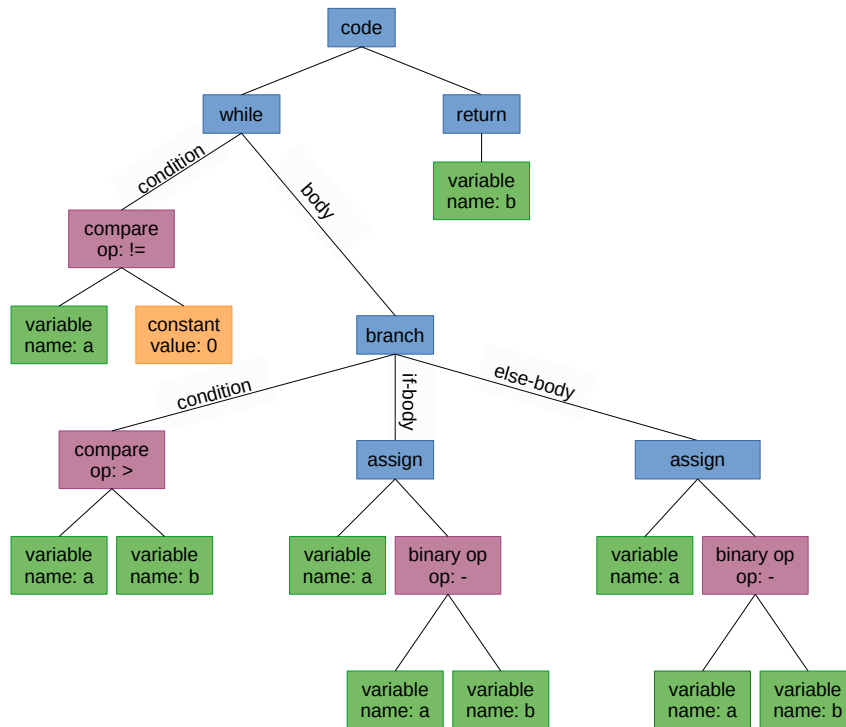


Abbildung 3.3: AST zum Euklidischen Algorithmus

Ein AST enthält somit nicht nur Informationen über die Tokens, sondern über die gesamten Strukturen und Abhängigkeiten, die sich aus den Tokens ergeben. Variabel- und Funktionsdefinitionen oder komplexe Statements wie 'if' oder 'for' sind im AST als *Nodes* enthalten. Wenn man die Nodes des AST von unten nach oben durchquert, erhält man die Reihenfolge der einzelnen Tokens ohne Abhängigkeitskonflikte. Eine Subtraktion kann zum Beispiel erst ausgeführt werden, wenn sowohl die linke als auch die rechte Zahl bekannt ist. Daher befindet sich, wie in Abbildung 3.3 ersichtlich, die Subtraktion über den beiden benötigten Werten im AST.

3.3 Semantische Analyse

Semantik ist die Wissenschaft der Bedeutung von Wörtern einer Menschensprache. Bei einem Compiler geht es bei der *semantische Analyse* nicht um Bedeutung sondern um die Korrektheit von Expressions. Wird eine Variable nicht konform ihres Datentyps verwendet, zum Beispiel wenn zwei Strings dividiert werden sollen, wird dies während der semantischen Analyse entdeckt und gemeldet. Gegebenenfalls kann ein impliziter Cast, also ein impliziter Wechsel des Datentyps, hinzugefügt werden. So geben zum Beispiel manche Programmiersprachen bei der Division zweier Ganzzahlen eine Fließkommazahl zurück. Auch werden unbekannte Variablen und Funktionen in diesem Schritt abgefangen. Weiter wird der Datentyp einer Node des AST an diese angebunden. Nach der semantischen Analyse sieht der AST aus Abbildung 3.3 wie folgt aus:

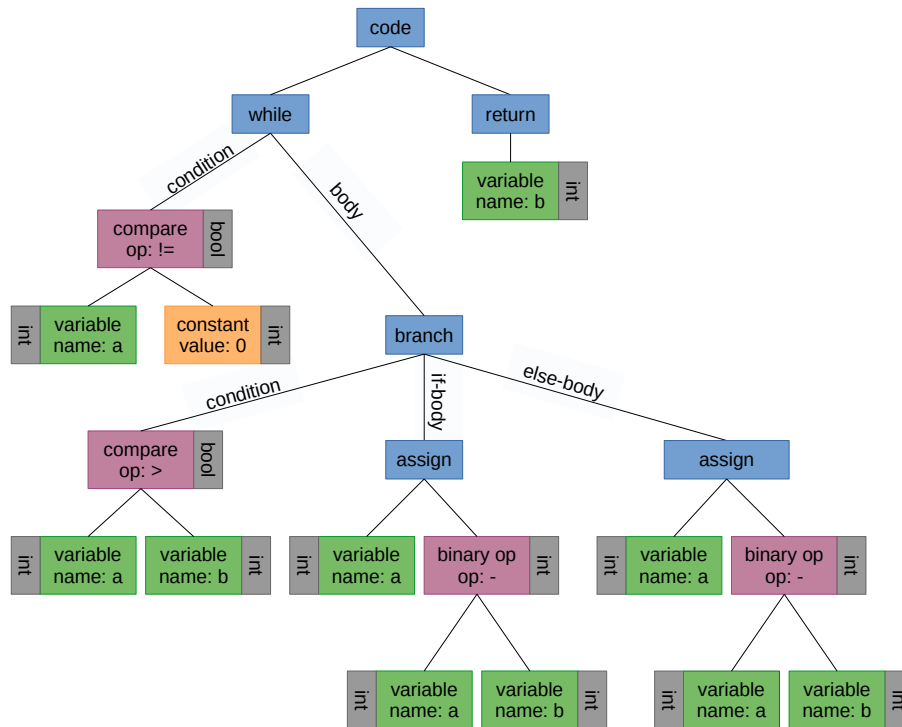


Abbildung 3.4: AST nach der semantischen Analyse

3.4 Codegenerierung

Codegenerierung ist der finale und oft auch komplexeste Schritt, der ein Compiler ausführen muss. Nun da die Eingabedatei als AST vorliegt, kann die Ausgabedatei generiert werden. Eine geläufige Methode der Codegenerierung ist die sogenannte *Macro Expansion*. Hierbei wird der AST von unten nach oben schrittweise mit Teilen an Ausgabecode ersetzt. Diese Ausgabecode-Teile sind häufig von den darunterliegenden Nodes abhängig.

MAYBE FIGURE OR LISTING AS EXAMPLE

3.5 Optimierung

Codegenerierung ist zwar der letzte Schritt beim Kompilieren, trotzdem wurde eine wichtige Aufgabe des Compilers noch nicht betrachtet. *Optimierung* geschieht zwischen jedem der genannten Schritte und dies häufig mehrmals. Dabei geht es darum die Ausgabedatei so effizient wie möglich zu machen. Effizient kann hierbei verschiedene bedeuten. Die Ausgabedatei muss so schnell wie möglich ausgeführt werden, Memory sparsam verwenden und dazu noch eine möglichst kleine Datei umfassen. Optimierungsmethoden reichen vom Überspringen der Kommentare und Umstellen von mathematischen Operationen, bis zum Entfernen

von ungebrauchten Variablen und sogenannten Deadstores. Es muss von CPU-Registern profitiert, mit Heap-Memory umgegangen und von Inline-Funktionen Gebrauch gemacht werden. Optimierung ist also sehr vielseitig und komplex. Wie Optimierung genau aussehen kann, wird daher in dieser Maturaarbeit nicht weiter betrachtet.

4 Der QHScompiler

Der QHScompiler basiert auf einem von mir erdachten alternativen Aufbau für einen Compiler. Diesem Aufbau liegt eine einfache Idee zugrunde: Die Macros die der Macro Expansion aus Abschnitt 3.4 sollen erst während der Kompilierung definiert werden. Auf dieser Grundidee werde ich zwei Dinge aufbauen. Erstens halte ich es für möglich, mit der richtigen Verwendung von Macros die gesamte syntaktische Analyse zu überspringen und keinen AST generieren zu müssen. Zweitens sollte es rein durch die Veränderung von diesen Macros möglich sein jegliche Programmiersprache zu kompilieren. Man könnte also in einem Dokument verschiedene Programmiersprachen verwenden und müsste dazwischen bloss die jeweiligen Macros neu definieren. Das selbige gilt ebenfalls für die Ausgabesprache. Nur durch das Umdefinieren der Macros liesse sich die Ausgabesprache wechseln, ohne eine Änderung am Compiler vornehmen zu müssen. Um dies zu verwirklichen, folgt mein alternativer Ansatz einem Aufbau, der sich stark von einem traditionellen Compiler unterscheidet.

Die Programmiersprache, in der sich meine Macros definieren lassen, bezeichne ich als QHS. Der Compiler der QHS versteht und kompiliert, nenne ich dazu passend den QHScompiler. QHS besteht wie die meisten anderen Programmiersprachen aus Wörtern. Im Kontext von QHS werden diese Wörter *Orders* genannt. Orders können drei verschiedenen Typen aufweisen: *Identifiers*, *Instructions* und *LiteralCode*. Wie diese drei Ordertypen genau funktionieren, wird in Abschnitt 4.3 ausführlicher erklärt.

Der Kompilierung durch den QHScompiler steht ein einfacher Zyklus (*QHS-Zyklus*) zugrunde, dessen Inspiration der Von-Neumann Zyklus ist.




Abbildung 4.1: Zyklus der QHS Kompilierung

4.1 Die Fetch-Phase

Die Aufgabe der *Fetch-Phase* ist es die nächste *Order*, die verarbeitet werden soll, zu finden. In dieser Hinsicht gleicht die Fetch-Phase der lexikalische Analyse eines traditionellen Compilers. Der QHS-Zyklus

beginnt bei der Fetch-Phase, dabei wird die erste *Order* aus der Eingabedatei extrahiert. In jeder weiteren Fetch-Phase wird die nächste *Order* aus der Eingabedatei geholt. Die Fetch-Phase ist auch dafür zuständig die nächste *Order* einem der drei Typen (Identifier, Instruction oder LiteralCode) zuzuordnen. Diese *Ordertypen* sind mit folgenden Regular Expressions definiert. Leerzeichen dienen als Trennung zwischen *Orders* und werden ignoriert.

Tabelle 4.1: RegEx Definitionen der *Ordertypen*

identifier	<identiferChar>+
instruction	# <identiferChar>+
literalCode	".*"

<identiferChar>	= [^# "<whitespace>"]
<whitespace>	= SPACE NEWLINE TAB

Im Vergleich zu traditionellen Compilern fällt auf, dass beim QHScompiler kaum zwischen Zeichen differenziert wird. Während die lexikalische Analyse traditionell zwischen vielen verschiedenen Tokens unterscheidet, sind für den QHScompiler alle Zeichen (mit Ausnahme von # und ") gleichbedeutend.

Normalerweise erhält die Fetch-Phase die nächste *Order* aus der Eingabedatei. Es ist jedoch möglich *Orders* der Eingabedatei voranzustellen. Diese *Orders* werden in der Fetch-Phase zuerst gefunden. Dies geschieht mithilfe des *FetchStacks*, auf den *Orders* gelegt werden können. In der nächsten Fetch-Phase wird immer die oberste *Order* des *FetchStacks* geholt und daraufhin vom *FetchStack* entfernt. Die Eingabedatei befindet sich auf dem untersten Platz des *FetchStacks* und wird somit nur verwendet, wenn der Stack ansonsten komplett leer ist.

FETCHSTACK FIGURE

Die Hauptanwendung des *FetchStacks* wird im Abschnitt 4.3 erklärt. Die Kompilierung ist beendet, sobald keine *Order* mehr auf dem *FetchStack* vorhanden ist.

4.2 Die Validate-Phase

Nachdem die nächste *Order* in der Fetch-Phase gefunden wurde, wird diese *Order* an die Validate-Phase weitergegeben. Während der Validate-Phase kommt die *OrderQueue* ins Spiel. Dabei handelt es sich, wie der Name schon sagt, um eine Queue von *Orders*. Die Aufgabe der *OrderQueue* ist das Speichern und spätere Zurückholen von *Orders*. Die *OrderQueue* kann mit Instructions, die im Abschnitt 4.3 weiter ausgeführt werden, aktiviert und deaktiviert werden. Wenn eine *Order* in die Validate-Phase gelangt und die *OrderQueue* aktiviert ist, wird diese *Order* der *OrderQueue* hinzugefügt. Die Execute-Phase wird danach übersprungen und der QHS-Zyklus beginnt von neuem bei Fetch. Die *Order* wurde (ohne die Execute-Phase erreicht zu haben) auf der *OrderQueue* gespeichert. Später ist es mit Instructions möglich diese *Order* von der *OrderQueue* zu entfernen und auszuführen.

Bestimmte *Orders* können jedoch *orderQueue-proof*, also immun gegen die *OrderQueue*, gemacht werden. *Orders*, die *orderQueue-proof* sind, werden an die Execute-Phase weitergegeben, auch wenn die *OrderQueue* aktiv ist. Dieses Prinzip ist zum Beispiel besonders bei der Instruction, welche die *OrderQueue* wieder deaktiviert, wichtig. Da diese Instruction ansonsten nicht zur Execute-Phase gelänge und somit

die *OrderQueue* nie deaktiviert würde. Zu beachten ist, dass *LiteralCode* nicht *orderQueue-proof* sein kann.

MAYBE CODESTACK FIGURE

Ist die *OrderQueue* deaktiviert oder die *Order orderQueue-proof*, wird diese *Order* an den letzten Schritt *Execute* weitergegeben.

4.3 Die Execute-Phase

Während der *Execute*-Phase wird der tatsächliche Assembly Code generiert. Je nach Typ der *Order* (Identifizier, Instruction oder *LiteralCode*) läuft die *Execute*-Phase sehr unterschiedlich ab. In den folgenden Abschnitten wird der Ablauf der *Execute*-Phase je nach *Ordertyp* erklärt.

4.3.1 Identifizier

Identifizier stehen für die am Anfang von Abschnitt 4 erwähnten Macros. Die Macros sind für den QHScompiler eine Liste an *Orders*. Identifizier lassen sich zu einer Liste an *Orders* definieren. Wenn nun ein Identifizier in die *Execute*-Phase gelangt, werden die dazugehörigen *Orders* auf den *FetchStack* aus Abschnitt 4.1 gelegt. Bei den nächsten *Fetch*-Phasen werden nun zuerst die zum Identifizier gehörenden *Orders* nacheinander abgebaut. Einfach ausgedrückt wird der Identifizier also durch seine *Orders* ersetzt. Als Beispiel seien folgende Identifizier definiert:

Tabelle 4.2: Definition von Beispiel Identifiern

Identifizier	Definition
id1	"lit1"
id2	#inst2.1 "lit2" #inst2.2
id3	id2 "lit3"

Mit diesen Identifiern, wird nun folgender Code kompiliert:

Auflistung 4.1: QHS Code zur Veranschaulichung von Identifiern

Eingabe
<pre>"lit0.1" id1 "lit0.2" id2 id3</pre>
Ausgabe
<pre>"lit0.1" "lit1" "lit0.2" #inst2.1 "lit2" #inst2.2 #inst2.1 "lit2" #inst2.2 "lit3"</pre>

Die Identifizier aus der Eingabe wurden mit ihren Definitionen ersetzt. Wie der Identifizier *id3* zeigt, ist es möglich Identifizier ineinander zu verschachteln.

Die Definitionen der Identifier sind in einem sogenannten *Environment* definiert. Bei einem *Environment* handelt es sich um eine einfache Map, die einen Identifier mit einer Liste an *Orders* verknüpft. Die bereits erwähnten *Environments* sind dabei in einer Linked-List gespeichert. Somit können neue *Environments* zu dieser Liste hinzugefügt und aus der Liste entfernt werden. Das letzte *Environment* der Liste ist das älteste und das erste *Environment* das neuste. Ein neuer Identifier wird immer zum ersten *Environment* hinzugefügt. Definitionen des gleichen Identifiers in älteren *Environments* werden nicht überschrieben oder gelöscht. Bei der Abfrage nach einem Identifier wird immer die neuste vorhandene Definition zurückgegeben. Ist keine vorhanden, wird ein Error ausgegeben.

4.3.2 Instructions

Wenn eine Instruction in die Execute-Phase gelangt, wird die dazu definierte Funktion im QHScompiler ausgeführt. Diese Funktionen können Variablen im QHScompiler speichern, die *OrderQueue* aktivieren, Identifier definieren und vieles mehr. Instructions sind somit der Weg wie während der Kompilierung auf den QHScompiler einfluss genommen werden kann. In der Tabelle 4.3 sind ein paar der wichtigsten Instructions aufgelistet:

Tabelle 4.3: Wichtige Instructions des QHScompilers

Instruction	Beschreibung
#enterOrderQueue	Aktiviert die <i>OrderQueue</i> . Diese Instruction ist <i>orderQueue-proof</i> .
#exitOrderQueue	Deaktiviert die <i>OrderQueue</i> . Diese Instruction ist <i>orderQueue-proof</i> .
#assign	Die erste <i>Order</i> der <i>OrderQueue</i> muss ein Identifier sein. Der Rest der <i>Orders</i> auf der <i>OrderQueue</i> wird als Definition für diesen Identifier festgelegt.
#assignToOne	Wie #assign, jedoch wird nach dem Identifier nur eine weitere <i>Order</i> von der <i>OrderQueue</i> genommen und als Definition für den Identifier verwendet.
#force	Die nächste <i>Order</i> wird nach der Fetch-Phase sofort an die Execute-Phase weitergegeben. Überspringt Validate und somit die <i>OrderQueue</i> . Diese Instruction ist <i>orderQueue-proof</i> .
#orderEnqueue	Die nächste <i>Order</i> wird sofort dem Ende der <i>OrderQueue</i> hinzugefügt, auch wenn diese <i>Order</i> <i>orderQueue-proof</i> wäre. Die Execute-Phase wird übersprungen.
#orderFrontEnqueue	Ähnlich wie #orderEnqueue. Die <i>Order</i> wird jedoch an den ersten Platz der <i>OrderQueue</i> gesetzt.
#deepFetch	Die nächste <i>Order</i> der Eingabedatei wird oben auf den FetchStack gesetzt. Ermöglicht den Zugriff auf die Eingabedatei innerhalb eines Identifiers.
#queueFetch	Die erste <i>Order</i> der <i>OrderQueue</i> wird oben auf den FetchStack gesetzt.
#pushEnv	Ein neues <i>Environment</i> wird der <i>Environment-Linked-List</i> hinzugefügt.
#popEnv	Das neuste <i>Environment</i> der <i>Environment-Linked-List</i> wird gelöscht.
#addToIdentifier	Die erste <i>Order</i> der <i>OrderQueue</i> muss ein Identifier sein und die zweiteste LiteralCode. Beide <i>Orders</i> werden als Zahl interpretiert und addiert. Das Resultat wird im Identifier gespeichert.

Der QHScompiler umfasst **33** Instructions, wobei **5** dieser ausschliesslich fürs Debuggen des Compilers dienen.

4.3.3 LiteralCode

LiteralCode ist der Weg wie der QHScompiler Assembly Code generiert. Dieser ist sehr einfach. Wenn LiteralCode in die Execute-Phase gelangt, wird alles, das zwischen den Satzzeichen steht, in die Ausgabedatei geschrieben. Dies ist die einzige Möglichkeit des QHScompiler Assembly Code zu generieren. Einzig die *LiteralCode-Orders* bestimmen, was in die Ausgabedatei gelangt, und somit welcher Sprache diese Ausgabedatei folgt. Durch das Anpassen der *LiteralCode-Orders* ist es also möglich die Ausgabesprache des QHScompilers zu ändern.

4.4 Definition der Macros

Somit ist der QHScompiler komplett. Grundsätzlich lässt sich mit QHS bereits jedes Programm schreiben und mit dem QHScompiler kompilieren. Jedoch habe ich in Tabelle 2.1 festgelegt, dass die Eingabesprache einen C ähnlichen Syntax aufweisen muss. Um dies zu ermöglichen, muss man, wie zu Beginn von Abschnitt 4 erwähnt, bestimmte Macros also Identifier definieren. In diesem Abschnitt werde ich zeigen, wie sich diese Identifier auch für syntaktisch komplexe Programmiersprachen definieren lassen. Zur Veranschaulichung dienen Variablen und Funktionsdefinitionen.

4.4.1 Die QHS Notation

In diesem Abschnitt wird viel QHS-Code als Beispiel verwendet. Um die Leserlichkeit von QHS zu verbessern, werden ein zuerst paar Identifier anstelle der umständlichen Instructions definiert. Diese Identifier sind in der folgenden Tabelle 4.4 aufgeführt.

Tabelle 4.4: Identifier als Abkürzung von Instructions

Identifier	Definition
[#enterOrderQueue
]	#exitOrderQueue
>>	#assign
->	#assignToOne
!	#force
\n	Eine neue Zeile in der Ausgabedatei

Weiter wird innerhalb von Kommentaren Pseudo-Code verwendet, um den QHS Code verständlicher zu erklären. Kommentare können mehrere Zeilen umfassen und beginnen immer mit `/*` und enden mit `*/`. Der Kommentar `/* X = "hello" #pushEnv */` würde bedeuten, dass der Identifier `X` zu den *Orders* `"hello"` (LiteralCode) und `#pushEnv` (Instruction) definiert wurde.

Auch wird bei längeren Identifier-Definitionen wird zuerst der zu definierende Identifier getrennt von den restlichen *Orders* der *OrderQueue* hinzugefügt. Diese Separation dient der besseren Leserlichkeit und hat keinen Einfluss auf die Kompilierung des Codes.

4.4.2 Beispiele zu Identifier-Definitionen

Wie die Definition von Identifiern ablaufen kann, soll in diesem Abschnitt an einigen Beispielen erklärt werden.

Auflistung 4.2: Beispiel zu gewöhnlichen Identifier-Definitionen

```

1      _____ Eingabe _____
2  [ id1 "lit1" ] ->
3  [ id2 "lit2.1" "lit2.2" id1 ] >>
4  [ id3 "lit3.1" ] [ "lit3.2" ] >>
5
6  id1 \n
7  id2 \n
8  id3
9
10     _____ Ausgabe _____
11
12  lit1
13  lit2.1 lit2.2 lit1
14  lit3.1 lit3.2

```

Die Linien 1 und 2 definieren die folgenden beiden Identifier:

```
id1 = "lit1"
```

```
id2 = "lit2.1" "lit2.2" id1
```

In Linie 3 wird die *OrderQueue* zwischendurch deaktiviert und wieder aktiviert. Dies hat keinen Einfluss auf die Kompilierung und wird daher, wie in Abschnitt 4.4.1 erwähnt, für die Verbesserung der Leserlichkeit von langen Identifier-Definitionen verwendet. Die *OrderQueue* sieht vor dem >> wie folgt aus, wobei das linke Element das erste darstellt:

```
id3 "lit3.1" "lit3.2"
```

Wie gewohnt wird id3 mit >> definiert:

```
id3 = "lit3.1" "lit3.2"
```

Auflistung 4.3: Beispiel zu #assignToOne

```

1      _____ Eingabe _____
2  [ id4 "lit4" ] >>
3  [ id5 "lit5" id6 ] ->
4  [ "lit6" ] >>
5
6  id4 \n
7  id5 \n
8  id6
9
10
11
12     _____ Ausgabe _____
13
14  lit4
15  lit5
16  lit6

```

Die Definition von id4 ist hier ähnlich wie in Linie 1 der Auflistung 4.2. Jedoch wird hier anstelle von -> (#assignToOne) der Identifier >> (#assign) verwendet. Da sich in beiden Fällen jedoch nur eine weitere *Order* neben dem Identifier auf der *OrderQueue* befinden, macht die Verwendung von >> keinen Unterschied. Bei Linie 2 und 3 ist dies jedoch anders. Zuerst werden drei *Orders* auf die *OrderQueue* gelegt. Der Identifier -> definiert daraufhin id5 wie folgt:

```
id5 = "lit5"
```

Der Identifier id6 verweilt auf der *OrderQueue*. Erst nachdem "lit6" der *OrderQueue* hinzugefügt wurde, wird id6 durch >> definiert:

```
id6 = "lit6"
```

Auflistung 4.4: Beispiel zu #orderFrontEnqueue

```

1      _____ Eingabe _____
2  [ "lit7.1" ]
3  #orderFrontEnqueue id7
4  [ "lit7.2" ] >>
5
6  id7
7
8
9
10     _____ Ausgabe _____
11
12  lit7.1 lit7.2

```

Zuerst gelangt "lit7.1" auf die *OrderQueue*. Daraufhin wird mit der Instruction #orderFrontEnqueue der Identifier id7 auf die erste Position der *OrderQueue* gesetzt. Die *OrderQueue* sieht daraufhin wie folgt aus.

```
id7 "lit7.1"
```

Der LiteralCode "lit7.2" wird normal hinten an die *OrderQueue* angefügt. Da sich der Identifier id7 auf dem ersten Platz der *OrderQueue* befinden, kann dieser definiert werden:

```
id7 = "lit7.1" "lit7.2"
```


Auflistung 4.5: Beispiel zu doppelter Aktivierung der *OrderQueue*

```

1  _____ Eingabe _____
2  [ id8 ]
3  [
4      "lit8.1"
5      [ "lit8.2" ]
6  ] >>
7
8  id8
9
10 _____ Ausgabe _____
11
12
13 lit8.1
14 Die OrderQueue enthält: "lit8.2"

```

In Auflistung 4.5 wird eine Identifier-Definition auf mehrere Zeilen geteilt. Dies dient der besseren Leserlichkeit und kompiliert gleich wie eine Definition auf nur einer Linie. Auf Linie 4 werden [(#enterOrderQueue) und] (#exitOrderQueue) innerhalb einer bereits aktiven *OrderQueue* verwendet. Im QHScompiler ist dies so implementiert, dass die beiden Identifier nicht ausgeführt und normal der *OrderQueue* hinzugefügt werden. Die *OrderQueue* enthält nach Linie 4 folgende Orders:

id8 "lit8.1" ["lit8.2"]

Die Identifier [und] gelangen normal in die *OrderQueue* und damit auch in die Definition von id8:

id8 = "lit8.1" ["lit8.2"]

Auflistung 4.6: Beispiel zu #force

```

1  _____ Eingabe _____
2  [ id9 "lit9" ] >>
3
4  [ id10 ]
5  [
6      ! id9
7      [ ! id9 ]
8  ] >>
9
10 id9 \n
11 id10
12
13
14
15
16 _____ Ausgabe _____
17
18 lit9
19 lit9
20 Die OrderQueue enthält: "lit9"

```

Zuerst wird in Linie 1 der Identifier id9 wie gewohnt definiert. In Linie 5 wird der Identifier ! (#force) verwendet. Die Instruction #force ist orderQueue-proof und zwingt den QHScompiler dazu, die nächste Order an die Execute-Phase weiterzugeben, obwohl die *OrderQueue* aktiv ist. Der Identifier id9 wird daher mit seiner Definition ersetzt. Die *OrderQueue* sieht nach Linie 5 wie folgt aus:

id10 "lit9"

In Linie 6 wird daraufhin der Identifier ! erneut verwendet. Dieses Mal jedoch innerhalb einer doppelten Aktivierung der *OrderQueue*, wie in Beispiel 4.5. In diesem Fall gelangen auch Orders die *orderQueue-proof* sind, nicht zur Execute-Phase. Der Identifier ! wird normal der *OrderQueue* hinzugefügt. Die folgende Definition von id10 lautet:

id10 = "lit9" [! id9]

Auflistung 4.7: Beispiel zu *Environments*

```

1  _____ Eingabe _____
2  [ id11 "lit11.1" ] >>
3  [ id12 "lit12" ] >>
4
5  id11 " " id12 \n
6
7  #pushEnv
8
9  [ id11 "lit11.2" ] >>
10 id11 " " id12 \n
11
12 #popEnv
13
14 id11 " " id12
15 _____ Ausgabe _____
16 lit11.1 lit12
17 lit11.2 lit12
18 lit11.1 lit12

```

Die Identifier id11 und id12 werden gewöhnlich definiert und angewendet. Daraufhin wird mit #pushEnv ein neues *Environment* hinzugefügt. In diesem *Environment* wird id11 umdefiniert. In Linie 11 wird die neuste Definition der beiden Identifier verwendet. Für id11 ist dies:

id11 = "lit11.2"

Der Identifier id12 ist immer noch wie folgt definiert:

id12 = "lit12"

Mit der Instruction #popEnv wird das neuste *Environment* gelöscht und die Umdefinition von id11 vergessen. Die Definition vom Identifier id11 ist wieder:

id11 = "lit11.1"

4.4.3 Parameter und Rückgabewert für Identifier

Mit den `#enterOrderQueue` (resp. `[]`) und `#exitOrderQueue` (resp. `]]`) Instructions kann innerhalb eines Identifiers die *OrderQueue* verwendet werden. Dies ermöglicht eine Art von Parameter und Rückgabewert für Identifier. Parameter werden vor dem Aufruf eines Identifiers der *OrderQueue* hinzugefügt. Diese können dann innerhalb des Identifiers verwendet werden. Genauso kann der Identifier *Orders* der *OrderQueue* hinzufügen und diese somit zurückgeben.

Auflistung 4.8: Verwendung von Parametern und Rückgabewert eines Identifiers

Eingabe	
<pre>[foo] [#orderFrontEnqueue param1 -> /* param1 = erstes Argument */ #orderFrontEnqueue param2 -> /* param2 = zweites Argument */ param1 " : " param2 \n /* param1 + " : " + param2 + "\n" */ ["Rückgabewert"] /* "Rückgabewert" wird der OrderQueue hinzugefügt */] >> ["Argument 1" "Argument 2"] /* 2 Argumente werden der OrderQueue hinzugefügt */ foo /* foo wird ausgeführt */ #queueFetch /* Die zurückgegebene Order wird von der OrderQueue geholt und ausgeführt */</pre>	
Ausgabe	
<pre>Argument 1 : Argument 2 Rückgabewert</pre>	

4.4.4 Variablen

Die Umsetzung von Variablen in QHS ist einfach. Um Platz für die Variable auf dem Stack zu schaffen, muss zuerst die Grösse der Variable (für dieses Beispiel 4 bytes für eine *int*) vom `rsp` subtrahiert werden. Dann wird für die Variable ein Identifier definiert, der zur Position der Variable auf dem Stack zeigt. Mit `LiteralCode` lässt sich dies wie folgt in QHS ausdrücken:

Auflistung 4.9: Definition einer Variable mit `LiteralCode`

Eingabe	
<pre>"sub rsp, 4" \n [a "[rbp-4]"] >> /* a = "[rbp-4]" */ "add " a ", 5"</pre>	
Ausgabe	
<pre>sub rsp, 4 add [rbp-4], 5</pre>	

Jedoch braucht man für diese Implementation immer noch viel `LiteralCode` und Assembly Kenntnisse. Um die Definition von Variablen C ähnlicher zu machen, lässt sich zum Beispiel ein `var` Identifier definieren. Dieser `var` Identifier nimmt die Grösse der Variable als Argument über die *OrderQueue* an. Um die in

C geläufige Syntax der Definition einer Variable beizubehalten, wird der Name der Variable mit der `#deepFetch` Instruction beschafft.

Auflistung 4.10: Definition einer Variable mit `var` Identifier

Eingabe
<pre>[var] [#orderFrontEnqueue size -> /* size = argument1 */ [name ! #deepFetch] >> /* name = Was nach dem var Identifier folgt */ "sub rsp, " size \n [! name "[rbp-4]"] >> /* name = "[rbp-4]" */] >> ["4"] var a "add " a " , 5"</pre>
Ausgabe
<pre>sub 4 add [rbp-4], 5</pre>

Momentan erhält jede Variable jedoch noch die Adresse `rbp-4`, weswegen sich die Variablen gegenseitig überschreiben würden. Der momentane `rbp`-Offset muss also gespeichert und erhöht werden. Dafür wird bereits am Anfang des Programms ein Identifier `rbpOffset` als 0 definiert. Mit der `#addToIdentifier` Instruction, lässt sich nun `rbpOffset` erhöhen. Dies kann folgendermassen aussehen:

Auflistung 4.11: Definition einer Variable mit `rbpOffset`

Eingabe
<pre>[rbpOffset "0"] >> /* rbpOffset = "0" */ [var] [#orderFrontEnqueue size -> /* size = argument1 */ [name ! #deepFetch] >> /* name = Was nach dem var Identifier folgt */ "sub rsp, " size \n [rbpOffset ! size] #addToIdentifier /* rbpOffset += size */ [! name "[rbp-" ! rbpOffset "]"] >> /* name = "[rbp-OFFSET]" */] >> ["4"] var a ["8"] var b "add " a " , 5" "sub " b " , 10"</pre>
Ausgabe
<pre>sub rsp, 4 sub rsp, 8 add [rbp-4], 5 sub [rbp-12], 10</pre>

Zuletzt lässt sich das umständliche Hinzufügen der Grösse der Variable sowie der *var* Identifier unter einem neuen Identifier zusammenfassen. Dies ist passenderweise die bekannte Bezeichnung für den Typen der Variable.

Auflistung 4.12: Definition einer Variable mit *int* Identifier

Eingabe
<pre>(...)</pre> <pre>[int]</pre> <pre>[</pre> <pre> ["4"] var</pre> <pre>] >></pre> <pre>int a</pre> <pre>int b</pre> <pre>"add " a ", 5"</pre> <pre>"sub " b ", 10"</pre>
Ausgabe
<pre>sub rsp, 4</pre> <pre>sub rsp, 8</pre> <pre>add [rbp-4], 5</pre> <pre>sub [rbp-12], 10</pre>

Nun sieht die Definition und Verwendung einer Variable genau so aus, wie es in C gebräuchlich ist. Auf das Setzen von Variablen werde ich hier nicht weiter eingehen, da dies mit den Methoden, die im nächsten Abschnitt 4.4.5 erklärt werden, funktioniert.

4.4.5 Funktionsdefinitionen

Funktionen sind im Vergleich zu Variablen komplizierter. Nachfolgend sollen zwei der Probleme von Funktionsdefinitionen behandelt werden. Anhand einer Funktionsdefinition, wie sie zum Schluss aussehen sollte, will ich die beiden Probleme erläutern:

Auflistung 4.13: Ziel für die Definition einer Funktion in QHS

<pre>int foo (int param1 , int param2)</pre> <pre>{</pre> <pre> (...)</pre> <pre>}</pre>

Hier lässt sich bereits das erste Problem feststellen. Im vorherigen Abschnitt 4.4.4 wurde der *int* Identifier für die Definition einer Variable verwendet. Das *int* in der Auflistung 4.13 würde daher vom QHScompiler als Definition für eine Variable verstanden werden. Der Unterschied zwischen Variable- und Funktionsdefinition besteht hierbei in den Klammern, die auf den Namen folgen. Der QHScompiler müsste also beim *int* Identifier nach vorne schauen, ob sich eine Klammer nach dem Namen befindet, und folglich eine Variable- oder Funktionsdefinition ausführen. Bei einem traditionellen Compiler würde diese Überprüfung während der syntaktischen Analyse ausgeführt werden. Dies ist dem QHScompiler jedoch nicht möglich, da dieser, wie zu Beginn von Abschnitt 4 erläutert, über keine syntaktische Analyse verfügt. Glücklicherweise lässt sich dieses erste Problem lösen, ohne eine Änderung am QHScompiler vorzunehmen. Die Lösung basiert darauf, beim *int* Identifier sowohl eine Variable- als auch eine Funktionsdefinition vorzubereiten, aber

keine der beiden bereits auszuführen. Daraufhin werden zwei Identifier definiert, erstens eine Klammer für eine Funktionsdefinition und zweitens ein Semikolon für die Definition einer Variable. Befindet sich nach dem Namen eine Klammer, wird eine Funktionsdefinition ausgeführt, ist dort aber ein Semikolon wird eine Variable definiert. Dieses Konzept wird im weiteren als *DelayedExecute* bezeichnet. Das Ganze sieht danach wie folgt aus:

Auflistung 4.14: Implementation eines DelayedExecute für Definitionen

```
(Definition einer Variable aus Auflistung 4.11)

[ function ]
[
  #orderFrontEnqueue returnSize ->          /* size = argument1 */
  #orderFrontEnqueue name ->                /* name = argument2 */

  [ ! name ] #orderToLiteral ":" \n          /* "foo:" */
] >>

[ definition ]
[
  #orderFrontEnqueue size ->                /* size = argument1 */
  [ name ! #deepFetch ] >>                  /* name = Was nach dem var Identifier folgt */

  [ ; ]
  [
    [ #orderEnqueue ! size #orderEnqueue ! name ] var
  ] >>
  /* ; = [ size name ] var */

  [ ( ]
  [
    [ #orderEnqueue ! size #orderEnqueue ! name ] function
  ] >>
  /* ( = [ size name ] function */
] >>

[ int ]
[
  [ "4" ] definition
] >>
```

Das zweite Problem sind die Parameter einer Funktionsdefinition. Diese sehen genau gleich aus wie die Definition einer Variable, sollten jedoch vom QHScompiler anders ausgeführt werden. Erstens sollte bei einer Parameterdefinition nicht der LiteralCode zur Subtraktion vom `rsp` hinzugefügt werden. Zweitens verwendet eine Parameterdefinition einen anderen `rbp`-Offset. Die Lösung liegt im Umdefinieren des *definition* Identifiers. Dieser ist momentan für die Definition von Variablen und Funktionen verantwortlich. Bei der Anfangsklammer der Funktionsdefinition wird der *definition* Identifier neu definiert, sodass er eine Parameterdefinition ausführt. Die vorherige Definition geht dank der `#pushEnv` Instruction nicht verloren. Bei der schliessenden Klammer wird `#popEnv` durchgeführt, und der *definition* Identifier ist wieder für Variablen und Funktionen zuständig. Diese Lösung wird im folgenden *TempAssign* genannt. Dies lässt sich in QHS wie folgt umsetzen:

Auflistung 4.15: Implementation eines TempAssigns für Parameter Definitionen

```
[ function ]
[
    #pushEnv

    #orderFrontEnqueue returnSize ->      /* size = argument1 */
    #orderFrontEnqueue name ->           /* name = argument2 */

    [ ! name ] #orderToLiteral ":" \n      /* "foo:" */

    [ definition paramDefinition ]         /* definition = paramDefinition */

    #popEnv                               /* Umdefinition von definition wird vergessen */
] >>
```

Der Identifier *paramDefinition* ist ähnlich wie der *var* Identifier aus Abschnitt 4.4.4. Es wird bloß anstelle von *rbpOffset* ein neuer *paramOffset* Identifier verwendet und der Assembly Code fürs Subtrahieren vom *rsp* nicht hinzugefügt.

Nun fehlt nur noch etwas an der Funktionsdefinition: Der Funktionsbody. Dieser ist vergleichsweise einfach. Die beiden geschwungenen Klammern werden zu einem leeren Identifier definiert und somit ignoriert. Der gesamte Code innerhalb des Body wird ganz normal vom QHScompiler ausgeführt und an die Ausgabedatei angehängt. Das Endresultat sieht wie folgt aus:

Auflistung 4.16: Finale Definition einer Funktion in QHS

	Eingabe
<pre>int foo (int param1 , int param2) { "add " param1 " , " param2 }</pre>	
	Ausgabe
<pre>foo: add [rbp+16], [rbp+20]</pre>	

Wie das Beispiel der Funktionsdefinition zeigt lassen sich mit *DelayedExecute* und *TempAssign* auch syntaktisch komplexe Programmiersprachen in QHS definieren und mit dem QHScompiler kompilieren.

Um einen C ähnlichen Syntax zu ermöglichen, braucht der QHScompiler noch viele weitere Identifier. Da diese jedoch einem ähnlichen Prinzip wie die beschriebenen Definitionen von Variablen und Funktionen folgen, werde ich sie hier nicht weiter betrachten.

5 Auswertung des Compiler Vergleichs

Abschliessend will ich den QHScompiler, wie in Abschnitt 2 beschrieben, mit zwei weiteren Compilern vergleichen. Verglichen werden die Compiler in Geschwindigkeit der Kompilierung, Geschwindigkeit der Ausgabedatei, Umgang mit fehlerhaftem Code und Offenheit für Erweiterung.

5.1 Geschwindigkeit der Kompilierung

Für die Messung der Kompilierungsdauer wird eine Funktion, die prüft, ob eine Zahl eine Primzahl ist, kompiliert. Diese Funktion wurde so geschrieben, dass jedes Feature, das alle drei Compiler unterstützen, verwendet wird. Dazu gehören Variablen, Funktionen und Expressions sowie If-Else-Statements und Loops. Die Funktion wurde in die jeweiligen Sprachen übersetzt und mehrmals in das Programm eingefügt. Anschliessend wurde jedes Programm zehnmal kompiliert. Die durchschnittliche Dauer der Kompilierung ist in Abbildung 5.1 ersichtlich.




Abbildung 5.1: Vergleich der Kompilierungsdauer mit Log-Log Skalen

Der THScompiler glänzt bei einer kleinen Programmgrösse mit einer sehr schnellen Kompilierung, doch steigt die Kompilierungsdauer mit einer zunehmenden Anzahl an Funktionen exponentiell an. Ab 10^4 Kopien der Funktion kompiliert der THScompiler länger, als die beiden anderen Compiler. Bei noch grösseren Eingabedateien ist zu erwarten, dass der THScompilers weiterhin langsamer kompiliert als GCC und der QHScompiler. Für die exponentielle Kompilierungsdauer des THScompilers habe ich leider keine Erklärung. Theoretisch sollten alle Schritte, die der THScompiler durchläuft, eine lineare Komplexität aufweisen. Trotzdem kompiliert der THScompiler bei wenigen Kopien der Funktion deutlich schneller als GCC, obwohl beide Compiler dem traditionellen Aufbau folgen. Dies liegt wahrscheinlich daran, dass der THS-

compiler über weniger Funktionalitäten als GCC verfügt. Der QHScompiler, der einen ähnlichen Umfang wie der THScompiler umfasst, wird für kleine Eingabedateien klar vom THScompiler geschlagen.

Sowohl der QHScomiler als auch GCC beginnen mit einer hohen Kompilierungsdauer bei einer tiefen Anzahl an Funktionen, verhalten sich später aber linear. Der Unterschied zwischen den Kompilierungsauern von GCC und dem QHScompiler erscheint durch die logarithmischen Skalen konstant. Tatsächlich braucht der QHScompiler aber ab einer Programmgrösse über 10^2 Funktionskopien ungefähr 1.5 mal länger als GCC.

Somit schneidet sowohl bei kleinen als auch bei grossen Eingabedateien der traditionelle Compiler Aufbau besser ab, als mein alternatives Modell.

5.2 Geschwindigkeit der Ausgabedatei

Die Geschwindigkeit eines kompilierten Programmes wird anhand eines Algorithmus zur Berechnung von Primzahlen gemessen. Wie bei der Funktion aus Abschnitt 5.1 ist dieser Algorithmus so geschrieben, dass er möglichst jedes von allen drei Compilern unterstützte Feature verwendet. Der Algorithmus wurde für verschiedene Mengen an zu berechnenden Primzahlen je zehnmal ausgeführt und die Ausführungsdauer gemessen. In der folgenden Abbildung 5.2 ist die durchschnittliche Ausführungsdauer der Programme nach Menge an berechneten Primzahlen dargestellt.




Abbildung 5.2: Vergleich der Ausführungsdauer mit GCC Optimierung

Wie in Abbildung 5.2 ersichtlich, beginnen alle drei kompilierten Programme mit einer sehr tiefen Ausführungsdauer. Die Programme des THS- und QHScompilers werden bis zum Schluss nahezu gleich schnell ausgeführt. Das von GCC generierte Programm ist jedoch deutlich schneller als die Programme des THS- und QHScompilers. Dies liegt ganz klar an den Optimierungsmethoden von GCC. Wenn man die Optimierung beim Kompilieren mit GCC deaktiviert, sieht die Abbildung wie folgt aus:




Abbildung 5.3: Vergleich der Ausführungsdauer ohne GCC Optimierung

Wie Abbildung 5.2 zeigt, wird das GCC Programm ohne Optimierung nur noch leicht schneller ausgeführt als die Programme der beiden anderen Compiler. Da ebenfalls weder der THS- noch der QHScompiler über Optimierungsmethoden verfügen, ist dies das erwartete Resultat. Aus zeitlichen Gründen war es mir nicht möglich Optimierung in meine beiden Compiler einzubauen.

Zusammengefasst lässt sich sagen, dass ohne Optimierung mein alternativer Aufbau eines Compilers ungefähr gleich schnelle Ausführungsgeschwindigkeit liefert, wie ein traditioneller Compiler. Trotzdem muss man anmerken, dass Optimierung bei einem traditionellen Compiler möglich ist und die Ausführungsdauer deutlich verringert, wie GCC in Abbildung 5.2 beweist. Ich kann mir vorstellen, dass Optimierung für einen nach meinem alternativen Aufbau entwickelten Compiler jedoch deutlich schwierig wäre. Traditionelle Compiler haben die Möglichkeit Optimierungen auf dem AST auszuführen. Für meinem alternativen Compiler ist dies nicht möglich, da gar keine syntaktische Analyse durchgeführt und nie ein AST generiert wird. Auch steht die Grundidee meines alternativen Aufbaus Optimierung stark im Weg. Wie zu Beginn von Abschnitt 4 beschrieben, basiert mein Ansatz darauf, dass die von Macro Expansion verwendeten Macros während der Kompilierung erst definiert werden. Daher kennt der QHScompiler vor der Kompilierung weder die Eingabe- noch die Ausgabesprache. Dies führt dazu, dass auch mögliche Optimierungsmethoden erst während dem Kompilieren gefunden werden können. Aus diesen Gründen wäre Optimierung für einen Compiler nach meinem alternativen Aufbau deutlich komplexer, wenn nicht sogar unmöglich.

5.3 Umgang mit fehlerhaftem Code

GCC und der THScompiler folgen beide einer exakt definierten Syntax und einer klaren Semantik. Wird die Syntax oder Semantik nicht eingehalten wird ein Fehler gemeldet. Dies ist ein Resultat der syntaktischen und semantischen Analyse, die nach bestimmten Regeln geschrieben wurden und diese Regeln exakt einhalten. Traditionelle Compiler erscheinen dadurch manchmal etwas pingelig. Jedoch sind sie dafür sehr genau und hilfreich beim Finden und Melden von Fehlern.

Der QHScompiler arbeitet hingegen viel ungenauer. Wie im Abschnitt 4.4.5 bereits beschrieben, verfügt

der QHScompiler über keine Möglichkeit zu überprüfen, ob eine bestimmte *Order* folgt oder nicht. Er führt konsequent nur aus, was als Nächstes auftaucht. Darum führt ein fehlendes Zeichen nicht immer zu Fehlern. Folgender Code soll dies veranschaulichen:

Auflistung 5.1: QHS mit fehlenden Tokens

```
int a = "69"    /* ; fehlt */
foo ( a ;      /* ) fehlt */
```

Der Code aus Auflistung 5.1 lässt sich einwandfrei vom QHScompiler kompilieren und daraufhin ausführen. Weder das Fehlen des Semikolons noch der schliessenden Klammer führt bei QHScompiler auf eine Fehlermeldung. Die resultierende Ausgabedatei ist ebenfalls fehlerfrei und lässt sich einwandfrei ausführen. Dies ist jedoch bei folgendem Beispiel nicht mehr der Fall.

Auflistung 5.2: QHS mit fehlender öffnender Klammer

```
int a = "69"    /* ; fehlt */
foo a ) ;      /* ( fehlt */
```

Der Code bei Auflistung 5.2 kompiliert problemlos, der generierte Assembly Code ist jedoch fehlerhaft. Die Funktion foo wird nicht ausgeführt und die Variable a nicht als Argument erkannt. Es entsteht also eine fehlerhafte Ausgabedatei, ohne dass der QHScompiler dies meldet.

Führt die Kompilierung doch zu einer Fehlermeldung, ist diese nicht immer besonders verständlich.

Auflistung 5.3: QHS mit falscher Anzahl Argumente

Eingabe
<pre>void foo () { } start { int a = "69" foo (a) ; exit ; }</pre>
Ausgabe
<pre>[ERROR] Cannot dequeue, OrderQueue is empty! [ERROR] Expected LiteralCode for #literalToIdentifier at OrderQueue second, got: NONE [ERROR] Cannot dequeue, OrderQueue is empty! [ERROR] Tried #changeIntVar but second order (change) from OrderQueue is not direct code [ERROR] Expected LiteralCode for #literalToIdentifier, got: NONE [ERROR] Expected LiteralCode for #literalToIdentifier, got: NONE [ERROR] Expected LiteralCode for #literalToIdentifier, got: NONE</pre>

Bei Auflistung 5.3 wird die Funktion foo ohne Parameter definiert, später jedoch mit einem Argument aufgerufen. Der QHScompiler verfügt über keine Möglichkeit, die Menge an Argumenten zu überprüfen, und meldet nicht direkt einen Fehler. Sobald er jedoch versucht die Grösse des erwarteten Argumentes von der *OrderQueue* zu holen ist diese leer. Der QHScompiler meldet einen *OrderQueue-Empty* Error gefolgt von vielen Folgefehlern.

Somit ist der QHScompiler bei der Meldung von Fehlern einerseits nicht sehr streng, andererseits aber auch verwirrend und ungenau bei der Fehlermeldung. Deshalb komme ich zum Schluss, dass der traditionelle

Compiler Aufbau mit syntaktischer und semantischer Analyse deutlich besser mit Fehlern umgehen kann als mein alternatives Modell.

5.4 Offenheit für Erweiterung

C, als eine auch professionell verwendete Programmiersprache, umfasst eine Vielzahl an Features. Zum Beispiel lassen sich mittels Templates Datenstrukturen wie Stacks, Queues oder Vectors definieren, die Datentyp unabhängig sind. Mit Libraries lassen sich zudem komplexe Algorithmen einmal schreiben und später einfach wieder verwenden. Solche Funktionalitäten sind bei einem traditionellen Compiler möglich.

Mit dem QHScompiler lassen sich Libraries ebenfalls verwenden. Templates sollten theoretisch ebenfalls möglich sein, jedoch habe ich dies nicht getestet. Jedoch bietet der QHScompiler, wie in Abschnitt 4 bereits angemerkt, noch weitere Möglichkeiten zur Erweiterung. Das Definieren von Identifiern während der Kompilierung ermöglicht es ganz unterschiedliche Programmiersprachen mit dem QHScompiler zu kompilieren. Gegebenenfalls falls kann die Programmiersprache sogar innerhalb der Eingabedatei geändert werden. Leider ist die Definition der benötigten Identifier für eine Programmiersprache nicht besonders intuitiv und benötigt Methoden, wie die Abschnitt 4.4.5 erklärten `DelayedExecute` und `TempAssign`. Trotzdem würde ich sagen, dass der QHScompiler einem mehr Freiheit bei der Erweiterung bietet, als ein traditioneller Compiler.

5.5 Fazit

Im Vergleich mit traditionellen Compilern zeigt der von mir entwickelte QHScompiler einige Schwächen. Er ist sowohl in der Geschwindigkeit der Kompilierung als auch bei der Ausführungsdauer eines kompilierten Programmes einem traditionellen Compiler unterlegen. Beim Umgang mit Fehlern ist der QHScompiler weniger streng aber auch deutlich unpräziser und verwirrender als Compiler nach dem traditionellen Aufbau. Als einziger Vorteil lässt sich seine Offenheit für Erweiterung sehen.

Mithilfe eines Profilers habe ich die Kompilierungsdauer des QHScompilers analysiert. Daraus schloss ich, dass das System der Identifier besonders ineffizient ist. Jeder Identifier benötigt zuerst eine Abfrage bei den *Environments*. Diese Abfrage ist an sich keine aufwendige Sache, jedoch sind Identifier häufig sehr ineinander verschachtelt. Daher werden auch für kurzer Code sehr viele Identifier ausgeführt. Generell liesse sich die Implementation der Identifier sicherlich stark verbessern und der gesamte QHScompiler optimieren.

Aus dem Vergleich der Umgang mit fehlerhaftem Code wird ausserdem klar, dass die syntaktische Analyse für die angenehme Verwendung eines Compilers äusserst wichtig ist. Durch den Parser lassen sich Fehler in der Eingabedatei früh finden und genau Melden. Dem QHScompiler ist dies, folge der fehlenden syntaktischen Analyse, nicht möglich.

Ausserdem ist ein AST, wie in Abschnitt 5.2 thematisiert, auch für die Optimierung der Ausgabedatei äusserst praktisch. Grundsätzlich ist Optimierung für den QHScompiler äusserst schwierig. Da die Eingabesprache während der Kompilierung erst definiert wird, müssten auch passende Optimierungsmethoden spontan gefunden werden. Dies äussert sich in einer langsameren Geschwindigkeit der Ausgabedatei.

Der einzige Vorteil des QHScompilers liegt in der Offenheit für Erweiterung. Das Wechseln der Programmiersprache innerhalb einer Datei ist definitiv interessant, jedoch habe ich noch kein Beispiel gefunden, wofür dieser Wechsel nötig wäre. In den meisten Fällen könnte man auch die Teile mit unterschiedlichen Sprachen auf mehrere Dateien aufteilen, einzeln kompilieren und danach mit einem *Linker* kombinieren.

Zusammengefasst führen während der Kompilierung definierte Identifier zu hohen Kompilierungsauern, ungenauem Umgang mit Fehlern und mangelhafter Optimierung der Ausgabedatei. Der QHScompiler ist einem traditionellen Compiler also stark unterlegen.

6 Schluss

Der QHScompiler kann einem traditionellen Compiler im Vergleich leider nicht das Wasser reichen. Trotzdem habe ich mit meiner Arbeit das erreicht, was ich mir erhofft hatte. Der Auslöser für meinen alternativen Ansatz war die Frage: Wieso werden Compiler so entwickelt, wie sie entwickelt werden? Dies konnte ich für mich ganz klar beantworten. Die syntaktische Analyse, die ich zuerst für unnötig hielt, erfüllt eine wichtige Aufgabe für Fehlermeldung und Optimierung. Ausserdem ist man dank ihr nicht auf verwirrende Methoden wie `DelayedExecute` oder `TempAssign` aus Abschnitt 4.4.5 angewiesen. Das Definieren der Macros und somit der Eingabe- und Ausgabesprache während der Kompilierung klingt zuerst verlockend, bringt jedoch auch Probleme fürs Optimieren der Ausgabedatei mit sich. Compiler folgen also aus gutem Grund dem traditionellen Aufbau.

Es hat mir sehr viel Spass gemacht meinen alternativen Ansatz zu entwickeln. Auch wenn es häufig frustrieren kann, ist es doch viel aufregender einer eigenen Idee zu folgen, als einfach stur dem traditionellen Weg zu folgen. Sowohl bei der Entwicklung des QHS- als auch des THScompiler stiess ich häufig gegen eine Wand und bemerkte dies meist erst, als ich schon eine Woche daran verloren hatte. Sehr hilfreich war es dabei die Entwicklung parallel bereits in Worte zu fassen. Die Verschriftlichung meiner Gedanken half mir dabei ein Verständnis aufzubauen, wie mein Programm tatsächlich funktioniert. Leider ist mir dies erst sehr spät aufgefallen.

Zuletzt möchte ich nochmals hervorheben, wie wichtig die Vorlesung *Compiler Construction* der Universität Bern für diese Maturaarbeit war. Ohne diese Vorlesung wäre es für mich viel schwieriger gefallen den traditionellen Aufbau eines Compilers zu verstehen und umzusetzen. Meine Maturaarbeit wie sie jetzt steht, wäre ohne die Vorlesung wahrscheinlich nicht möglich gewesen.

Abbildungsverzeichnis

3.1	Schritte, die ein Compiler durchläuft (https://github.com/munificent/craftinginterpreters , besucht am 5.8.2024)	6
3.2	Schritte, die in dieser Arbeit behandelt werden (Basierend auf Abbildung 3.1)	6
3.3	AST zum Euklidischen Algorithmus. (https://en.wikipedia.org/wiki/Abstract_syntax_tree , besucht am 5.8.2024)	8
3.4	AST nach der semantischen Analyse (Basierend auf Abbildung 3.3)	9
4.1	Zyklus der QHS Kompilierung	11
5.1	Vergleich der Kompilierungsdauer mit Log-Log Skalen	23
5.2	Vergleich der Ausführungsdauer mit GCC Optimierung	24
5.3	Vergleich der Ausführungsdauer ohne GCC Optimierung	25

Auflistungsverzeichnis

3.1	C code vor lexikalischer Analyse	7
3.2	Tokens nach lexikalischer Analyse	7
4.1	QHS Code zur Veranschaulichung von Identifiers	13
4.2	Beispiel zu gewöhnlichen Identifier-Definitionen	16
4.3	Beispiel zu #assignToOne	16
4.4	Beispiel zu #orderFrontEnqueue	16
4.5	Beispiel zu doppelter Aktivierung der <i>OrderQueue</i>	17
4.6	Beispiel zu #force	17
4.7	Beispiel zu <i>Environments</i>	17
4.8	Verwendung von Parametern und Rückgabewert eines Identifiers	18
4.9	Definition einer Variable mit LiteralCode	18
4.10	Definition einer Variable mit <i>var</i> Identifier	19
4.11	Definition einer Variable mit <i>rbpOffset</i>	19
4.12	Definition einer Variable mit <i>int</i> Identifier	20
4.13	Ziel für die Definition einer Funktion in QHS	20
4.14	Implementation eines DelayedExecute für Definitionen	21
4.15	Implementation eines TempAssigns für Parameter Definitionen	22
4.16	Finale Definition einer Funktion in QHS	22
5.1	QHS mit fehlenden Tokens	26
5.2	QHS mit fehlender öffnender Klammer	26
5.3	QHS mit falscher Anzahl Argumente	26

Tabellenverzeichnis

2.1	Anforderungen an die Compiler	5
2.2	Vergleichskriterien der Compiler	5
4.1	RegEx Definitionen der <i>Ordertypen</i>	12
4.2	Definition von Beispiel Identifiern	13
4.3	Wichtige Instructions des QHScompilers	14
4.4	Identifizier als Abkürzung von Instructions	15

Literaturverzeichnis

- [1] Alfred V. Aho, Monica S. Lam, Ravi Sethi, and Jeffrey D. Ullman. *Compilers: Principles, Techniques, and Tools (2nd Edition)*. 2006.
- [2] Susan L. Graham. *Table-Driven Code Generation*. 1980. [Online; accessed 2024-09-07].